

RAPPORT — TEST DE VIE DE LA RUCHE (premier verdict sur données réelles)

Date : 2026-10-04 · **Auteurs :** Claude (agrégateur + harnais) × LYNX (writer + abeilles) · **Version :** v2 — **chiffres corrigés** (voir §4bis ERRATUM) · **Statut :** verdict primaire rendu, décomposition pré-enregistrée appliquée.

0. Pourquoi ce test existe

Le held-out classique est **contaminé** (au-delà de ~300k interactions, il ne mesure plus la calibration mais la mémorisation). On l'a jeté. Le nouveau verdict de la ruche est **le test de vie** : *une abeille neuve apprend-elle mieux AVEC le miel (la mémoire collective) qu'SANS ?*

1. ENGAGEMENT / GÉNÉALOGIE (scellé avant tout tirage)

Élément	Valeur
Probe (scellé)	probe_vie.npz — sha256 1c34d5efa67638bef639a72204bf6033cb4863dbe36fef2512854616a9af228b
Graine probe	20261004 (⊥ des niches data_seed 7/8/9) — n = 2000 items
Déterminisme probe	vérifié : 2 générations → même sha
Nectar	ehwaza/bebe-ia, commit b871661, resultats/nectar_lignes.jsonl
Nectar — blob git (LF)	sha256 cfebe88d112820d2ccefc1cf2705bd69bcce4be9ab79e57c121beabc4b80e0a4 (844 164 o)
Nectar — fichier local (CRLF)	sha256 293e7734d1875b94e0ab21b4097c30ed60c4460382529f168ed730df2edf4615 (844 167 o)
Écart blobs	3 octets = 3 fins de ligne (core.autocrlf)
Lignes h[:16]	caf9ea4280a3fa73 · ed28088771caafad · dcbc2b08701b687e
Chevauchement contexte	0.591 — calculé par LYNX ET recalculé par Claude (convergen ^{ts})
Chevauchement — note	UPPER BOUND : vec = histogramme de caractères ; 2 src distincts peuvent partager le même octet
Miel (fold → npz)	miel_phase1.npz — sha256 619105c33f5aed5e60b2c156a94b24bf815c405ea7a0e6eb20081a1fb70997af (1925 clés, Σn = 260 392)

Élément	Valeur
Consult (k voisins)	k = 5 (banc/harnais/loader LYNX) — voir §4bis
Bootstrap	2000 rééchantillons, graine 5 (reproductible)
β	0.5, figé AVANT tout résultat réel — pas de sweep
Graines	10
Chance (base)	$1/39 = 0.026$
Gel	poids init graine s , aucun entraînement , miel au consult seulement

2. HEADLINE

1. Un miel de ruche A CORRIGÉ une abeille neuve GELÉE (chance → .4-.5) sur sa niche ET sur les autres.
2. Mais la décomposition montre que le transfert est dominé par les contextes VUS ; la généralisation au neuf est faible.

3. MÉTHODE

Miel = fold du nectar des 3 abeilles (charger_miel , union des clés + somme des compteurs, plafond par abeille — ici inactif). Abeille neuve = poids **gelés** (graine **s** , jamais entraînés) + mémoire **vide** vs **miel**. Deux bras appariés, mêmes poids. Deux modes d'usage du miel :

- **SOUPLE (verdict primaire)** : $p = (1-\beta) \cdot p_{\text{modele}} + \beta \cdot p_{\text{knn}}$, $p_{\text{knn}} = \text{one-hot}(\text{maj}) \cdot sk$.
- **DUR (témoin)** : si $sk > 0.5 \rightarrow \text{pred} = \text{maj}$, $\text{conf} = sk$.

Probe scellé → 2 blocs **essence** (règles de SA niche) / **transfert** (règles des autres), croisés avec **vu** / **non-vu** (le contexte du probe a-t-il déjà été vu par les abeilles ? 59.1 % oui).

4. RÉSULTATS (v2)

4.1 Verdict primaire — MIEL UTILE sur les 3 niches, les 2 modes

niche	mode	essence (vide→miel)	transfert (vide→miel)
n0 (rep)	souple	+0.373 (.0235→.3966)	+0.434 (.0340→.4676)
n1 (arith miroir)	souple	+0.480 (.0313→.5110)	+0.383 (.0324→.4153)
n2 (saut rnd)	souple	+0.388 (.0367→.4243)	+0.445 (.0288→.4739)
n0	dur	+0.228 (.0235→.2512)	+0.212 (.0340→.2458)

niche	mode	essence (vide→miel)	transfert (vide→miel)
n1	dur	+0.170 (.0313→.2016)	+0.245 (.0324→.2774)
n2	dur	+0.253 (.0367→.2900)	+0.189 (.0288→.2177)

Les deux bras sont un modèle **à la chance** (.024–.045). Donc « MIEL UTILE » se lit ici comme « **le miel bat un neuf au hasard** » (conséquence de l'accord *gel*) — PAS « un neuf compétent ».

4.2 Décomposition vu / non-vu (SOUPLE) — le cœur du résultat

niche	strate	vide→miel	diff
n0	essence vu	.0234→.5025	+0.479
n0	essence non-vu	.0237→.2823	+0.259
n0	transfert vu	.0376→.6299	+0.592
n0	transfert non-vu	.0283→.2158	+0.188
n1	essence vu	.0324→.5050	+0.473
n1	essence non-vu	.0283→.5265	+0.498
n1	transfert vu	.0379→.7076	+0.670
n1	transfert non-vu	.0269→.1181	+0.091
n2	essence vu	.0451→.8105	+0.765
n2	essence non-vu	.0283→.0429	+0.015
n2	transfert vu	.0301→.5044	+0.474
n2	transfert non-vu	.0262→.4163	+0.390

Lecture : sur le **vu**, le miel atteint .50–.81 ; sur le **non-vu**, il tombe à .03–.53, et s'effondre par endroits (n2 essence non-vu +0.015 ; n1 transfert non-vu +0.091). Le « transfert d'essence » est donc **surtout de la récupération** de contextes déjà vus ; la **généralisation au contexte réellement neuf est faible**.

sk : moy **.397**, p50 .413, p90 .735, p99 .866, max **.996**.

4bis. ERRATUM — correction du `consult` (v1 → v2)

Défaut trouvé (04/10, ~05:00). L'agrégateur réglait le `k` du `consult` sur la **dimension des clés** (`k` = 39 = NV) au lieu du **nombre de voisins** (`k` = **5**, la valeur de `banc.MemoireConsolidee`).
Conséquence : les chiffres de la **v1** (rapport publié et audité) étaient calculés avec **39 voisins**.

Fix. `charger_miel` force `k` = 5 ; l'export `miel_phase1.npz` est **inchangé** (il ne contient que les tableaux, pas `k`). **Croisement prouvé** : le miel chargé par le **loader de LYNX** (`entraîner_local._charger_miel`, `banc.MemoireConsolidee(k=5)`) rend des `sk` **identiques** à mon fold — `max |Δsk|` = 0.00 sur 2000 items. Aucun décalage train/éval ne subsiste.

Ce qui change : les chiffres (acc, `sk`, `ov_prec`) montent (avec $k=5$ la masse `sk>0.5` est bien plus fournie). **Ce qui ne change pas : la conclusion** — MIEL UTILE partout, transfert dominé par le vu.

Effet sur les addenda v1 : - L'addendum **(b)** (« seule cellule où l'IC croise 0 » = `n2 essence non-vu`) **ne s'applique plus** : avec $k=5$, **aucune** cellule ne croise 0 ; `n2 essence non-vu` = **+0.0145**, IC [+0.0101, +0.0185] (petit mais positif). Le défaut $k=39$ créait un artefact de cellule croisant 0. - L'addendum **(c)** ($\sigma=0$) **ne s'applique plus** : plus aucun bloc dégénéré.

5. AJOUTS (conditions d'accord LYNX — appliqués au format v2)

a) Engagement → §1 (+ bloc dans `rapport_reel.json`).

b) cf. §4bis : la cellule qui croisait 0 était un artefact de $k=39$. En **v2**, la cellule la plus faible est `souple / n2 / essence_non-vu` = **+0.0145** IC [+0.0101, +0.0185] → **positive** (exclut 0), mais d'amplitude ~30× plus petite que le vu.

c) None retiré. Blocs $\sigma=0$: **aucun** en v2.

d) DUR vs SOUPLE — couverture contre précision, même verdict. DUR : `n_ov` = **637/2000**, précision **.706**. SOUPLE : `n_ov` = **1722/2000**, précision **.517**. En v2, le DUR **se déclenche fortement** (`sk` monte à .996), donc les deux modes ne divergent plus d'amplitude (+0.23/+0.17/+0.25 vs +0.37/+0.48/+0.39) — mais restent **distincts** (le souple voit plus, le dur est plus précis).

e) n_requis par bloc. `n_requis` > 10 sur **13 blocs**, maximum **147**. → **10 graines n'atteignent PAS la cible de largeur** sur ces blocs : le verdict reste **directionnel**.

6. GLOSSAIRE

- **Gel** — l'abeille neuve n'est pas entraînée : ses poids restent à l'init. On mesure le miel **seul**.
 - **Récupération vs généralisation** — le miel restitue d'abord ce que les abeilles ont **vu** ; il généralise faiblement à des contextes **neufs**.
-

7. LIMITES

- Base à la **chance** (gel) : « MIEL UTILE » = bat un neuf au hasard, pas un neuf compétent.
 - Probe à **graine distincte** (pas disjoint en contexte : 59.1 % vu).
 - **10 graines** : direction OK, largeur insuffisante sur 13 blocs (§5.e).
 - Chevauchement = upper bound (histogramme de caractères).
 - **v1 corrigée en v2** (§4bis) : le `consult` utilise $k=5$.
-

8. OUVERTURE (NON TESTÉE ICI)

Le **warm-start d'un neuf compétent** (apprendre *avec* le miel, au sens des poids) est la **Phase 2** : protocole pré-enregistré, nouveau probe scellé (`probe_phase2.npz` , graine 20261005). **Non testé ici.**

Fichiers : `F:\becvide\test_de_vie.py` (harnais), `charger_miel.py` (agrégateur, $k=5$), `bebe/nectar.py` (writer vendorfé), `miel_phase1.npz` , `rapport_reel.json` , `_check_croise_miel.py` (preuve $\Delta sk=0$).